育见先贤—基于多模态技术的历史人物交互式教育系统

张X[1)] 李XX[1)] 王XX[1)] 张X[1)] 郭X[1)]

[1)] (XXX, 北京市, 中国, XXX)

摘 要 传统教育以单向填鸭式灌输为主，难以在学生与知识之间建立情感纽带，导致学生缺乏学习热情、学习效果受限。尽管当前人工智能技术逐步赋能教育领域，但多数应用只停留在教学工具替代等层面，没有真正做到教学范式的革新，缺乏与学科核心素养的融合。为此本项目结合大规模语言模型推理、提示词工程、检索增强生成、幻觉检测、语音识别与合成、声音驱动的数字人合成等多模态技术，构建出一个历史人物交互式教育系统，其首先将学生的语音输入转化为文本形式，接着输入给大规模语言模型并得到模型的文本输出和输出可能出现幻觉的概率，随后将大规模语言模型的文本输出转化为语音形式，最后驱动合成历史人物视频。通过本项目提出的系统，学生们可以走出课本，走进历史，与“活过来”的先贤们面对面谈古论今，学习他们的思想理念，从而真正做到寓教于乐、寓教于行，为教育范式的革新注入新动力。

关键词 教育系统；大规模语言模型；提示词工程；检索增强生成；幻觉检测；语音识别与合成；数字人合成

EduSages: A Multimodal AI-Driven Interactive Educational System for Engaging with Historical Figures

ZHANG X[1)] LI X[1)] WANG X[1)] ZHANG X[1)] WANG X[1)] GUO X[1)]

[1)] (XXX, Beijing, China, XXX)

Abstract Traditional education primarily relies on one-way, rote learning methods, making it difficult to establish an emotional connection between students and knowledge. This often results in a lack of enthusiasm for learning and limited learning outcomes. Although artificial intelligence technology is gradually being integrated into education, most applications remain at the level of replacing teaching tools rather than truly revolutionizing teaching paradigms. They also lack integration with core disciplinary competencies. To address this, our project leverages multimodal technologies such as large language model reasoning, prompt engineering, retrieval-augmented generation, hallucination detection, speech recognition and synthesis, and voice-driven digital human synthesis. We have developed an interactive educational system featuring historical figures. The system first converts students' speech input into text, which is then processed by a large language model to generate textual responses along with a probability of hallucination. The text output is subsequently transformed into speech and used to drive the synthesis of a video featuring a historical figure. Through this system, students can go beyond textbooks and step into history, engaging in face-to-face conversations with "revived" historical figures to learn about their thoughts and philosophies. This approach truly integrates education with entertainment and practical application, injecting new momentum into the transformation of educational paradigms.

Keywords Education System; Large Language Model; Prompt Engineering; RAG; Hallucination Detection; Speech Recognition and Synthesis; Digital Human Generation

---

作者介绍见文末 *

1 引言

人工智能是引领新一轮科技革命和产业变革的战略性技术，是培育和发展新质生产力的重要引擎。近年来，我国将“人工智能 + 教育”纳入国家教育现代化战略的核心布局。2025 年 1 月，中共中央、国务院印发的《教育强国建设规划纲要（2024-2035 年）》明确提出“促进人工智能助力教育变革”，深化人工智能在课程改革中的应用。2025 年政府工作报告进一步强调“深入实施科教兴国战略”，持续推进“人工智能 +”行动。两会期间，教育部部长怀进鹏也宣布，我国将正式发布《人工智能教育白皮书》，强调通过 AI 赋能实现教育“个性化、高质量、大规模”的融合。当前，我国高度重视人工智能深度赋能教育领域，正以顶层设计推动教育的数字化、智能化转型。

传统教育的局限性主要体现在以下方面：一是课堂以单向填鸭式灌输为主，难以激发学生的主动性和创造力，历史人物的“距离感”以及课本文字的“生硬枯燥”导致学生缺乏学习热情；二是现有数字教育资源多以静态图文或视频呈现，无法构建沉浸式、交互性学习体验，学生难以与知识建立情感连接，学习效果受限。尽管当前人工智能技术逐步进入校园，但多数应用停留在编程训练或工具替代层面，缺乏与学科核心素养的深度融合。Z 时代学生作为网络时代的原住民，对互动性、趣味性学习体验的期待远超传统模式。

响应国家号召，为建设教育强国贡献力量，本项目基于人工智能多模态技术构建了一个**历史人物交互式教育系统**，解决了传统教育中存在的痛点。具体来说，项目通过**提示词工程**让**大规模语言模型**扮演历史人物，与用户进行交互式问答；通过**检索增强生成技术**让大规模语言模型可以访问更新、更可验证的信息，缓解模型存在的知识边界和幻觉问题；通过**幻觉检测技术**衡量大规模语言模型生成幻觉回复的概率，降低幻觉伴随的问题风险；通过**语音识别技术**将用户的语音输入转换为文本形式输入给大规模语言模型；通过**语音合成技术**将大规模语言模型的文本输出转换为语音形式；通过**声音驱动的数字人合成技术**用语音合成得到的音频输出驱动合成历史人物视频。上述技术的综合应用构建了一个互动性强、趣味性足的历史人物交互场景。

我们希望本项目能够为传统教育中的痛点提供一种有效解决方案，满足学生探索欲、激发其学习兴趣的同时，以情感共鸣潜移默化传递家国情怀与人文精神，加强学生的民族认同与文化自信。

2 相关原理

2.1 语音处理技术

2.1.1 语音识别

机器识别语音到文字的过程和人识别语音的过程类似：从录音文件或是麦克风收集的音频中提取特征，经过声学模型和语言模型的处理，最后得出识别结果的文字。提取特征的方式有很多种，本项目使用的来自 OpenAI 的 Whisper [1] 是利用 Mel 频谱图（Mel Spectrogram）来实现这一功能。

Whisper 的语音识别可分为四个阶段，分别是特征提取、声学模型、多任务训练以及预测和解码。首先在特征提取阶段，音频会进行预处理。具体而言，音频被重采样到 16000Hz，并转换为 80 通道的 Mel 频谱图。Mel 频谱图将音频信号转换为时间和频率的表示，这样更符合人耳对声音的感知方式。

然后是声学模型，其结构可以分为编码器和解码器。编码器由多层 Transformer [2] 块组成。音频特征通过两个卷积层和 GELU 激活函数处理，随后进入编码器的 Transformer 块，进一步提取特征。解码器使用带有位置嵌入的 Transformer 块，基于编码器输出的音频特征进行文本预测。解码器的输入包括特殊的任务标记，这些标记指定了当前处理的任务类型（例如语音识别、语音翻译等）。

在多任务训练阶段，Whisper 模型在多语言、多任务数据集上进行联合训练。训练数据集包含 680000 小时的标注音频，其中包括 117000 小时的多语言音频和 125000 小时的翻译数据。联合训练使得模型能够在不同任务和语言之间共享知识，提高了泛化能力和鲁棒性。训练过程中，使用数据并行技术和多种正则化方法（如动态损失缩放和激活检查点）来稳定训练过程。模型通过 AdamW [3] 优化器进行训练，并采用了学习率逐步衰减的策略。

最后，在实际使用时进行预测与解码。在预测阶段，模型根据输入的音频特征生成文本，结合上下文信息和任务标记进行预测。在解码阶段，模型使用 Beam Search 算法 [4] 进行解码，以提高生成文本的准确性和连贯性。模型还结合了温度调节策略和语音活动检测来处理长音频段的转录。

总体而言，Whisper 系统展示了通过大规模弱监督预训练实现鲁棒语音识别的潜力。该系统简化

了语音识别流水线，使用一个多任务、多语言的模型，显著提高了语音识别的性能表现和泛化能力。

2.1.2 语音合成

语音合成，即将文字转化为语音的技术 [5]。类似于人类的口述能力，它通过使用不同的音色来表达所需的内容。语音合成技术主要由语言分析部分和声学系统部分组成，也被称为前端和后端部分。语言分析部分根据输入的文本信息进行分析，生成相应的语言规范书，确定如何发音。声学系统部分根据语音分析部分提供的语言规范书，生成相应的音频，实现发声功能。

语言分析部分的工作流程包括文本结构与语种判断、文本标准化、文本转音素以及句读韵律预测。首先进行文本结构与语种判断，在输入待合成的文本后，需要判断其是什么语种，随后根据相应语种的语法规则，将整段文本切分为句子，并将切分好的句子传递到后续处理模块。

然后是文本标准化，合成文本中可能包含阿拉伯数字或字母，需要将其转化为文字。根据设置的规则，对合成文本进行标准化处理。例如，“请问您是尾号为 8967 的机主吗?”中的“8967”是阿拉伯数字，需要转化为汉字“八九六七”，以便进行后续的文字标音等工作。之所以没有转化为“八千九百六十七”，是因为在文本标准化的规则中，设定了“尾号为 + 数字”的格式规则。

接下来是文本转音素，在汉语的语音合成中，通常以拼音对文字进行标注。因此需要将文字转化为相应的拼音。然而，一些字存在多音字的情况，需要通过分词、词性句法分析来判断当前应使用哪个读音，以及它是几声的音调。例如，“南京市长江大桥”可以表示为“nan2 jing1 shi4 chang3 jiang1 da4 qiao2”或者“nan2 jing1 shi4 chang2 jiang1 da4 qiao3”。

最后进行句读韵律预测，人类在语言表达时常常带有语气和感情。语音合成的音频旨在模仿真实的人声，因此需要对文本进行韵律预测，包括停顿的位置和持续时间，哪些字或词需要重读，哪些词需要轻读等。这样可以实现声音的抑扬顿挫。

声学系统部分目前采用了三种主要技术，分别是波形拼接、参数合成和端到端语音合成技术。波形拼接语音合成技术通过事先录制大量的音频，以尽可能覆盖所有的音节音素，并基于统计规则的大型语料库将其拼接成对应的文本音频。因此，波形拼接技术是通过使用已有库中的音节进行拼接，实现语音合成的功能。

参数语音合成技术主要通过数学方法对已有录音进行频谱特性参数建模，构建文本序列与语音特征之间的映射关系，得到参数合成器。因此，当输入文本时，首先将文本序列映射为相应的音频特征，然后通过声学模型将音频特征转化为可听的声音。

端到端语音合成技术通过神经网络学习的方法，实现直接输入文本或注音字符，输出合成的音频。这种技术极大地简化了复杂的语言分析部分，因此对语言学知识的要求大大降低，并且能够实现多种语言的语音合成，不再受限于语言学知识。通过端到端合成的音频，效果更加接近真人声音。目前较热门的端到端技术包括 Wavenet [6]、Tacotron [7]、Tacotron2 [8] 和 DeepVoice3 [9] 等。

当前已有许多厂商拥有语音合成技术，包括大型互联网公司和专注于人工智能领域的企业。其中科大讯飞在全球范围内的语音合成技术位居前列，其合成音频的自然度很高，官网提供的音库数量最多，涵盖了许多场景和外语音库。其提出的端到端 SMART-TTS 框架，将语音合成的学习过程进行模块化拆解，通过预训练加强各个模块学习，而非一开始就直接学习文本与声学特征的映射。

2.2 大规模语言模型

语言建模是一种运用人工智能算法来理解并掌握语言的方法。在过去的 20 年里被广泛研究。从基于统计的语言模型，发展到早期基于神经网络的语言模型，再到如今大火的预训练语言模型。预训练语言模型在解决各种自然语言任务上有着出色的性能表现。研究人员也发现，预训练语言模型的规模越大，参数量越多，预训练语言模型在解决一些下游特定任务时的性能就越显著，而且还表现出一些小规模预训练语言模型不具备的能力，如上下文学习等 [10]。近年来，对大规模预训练语言模型的研究得到了研究者的青睐。

2.2.1 大规模语言模型的发展

大规模语言模型是一种机器学习模型，其通过大量的文本数据进行预训练，把文本数据中的语言学知识存储到模型参数里，从而可以自动理解自然语言的语法和语义。

最初的预训练语言模型使用 LSTM [11] 作为特征抽取器，如 ELMo [12] 等。但 LSTM 特征抽取器的表达能力不够强，随着模型规模的增加，需要大量的训练数据来支撑，但 LSTM 特征抽取器不能有效地吸收数据里面蕴含的语言学知识。相比而言，

Transformer 综合特征抽取能力更强 [2]。于是，以 Transformer 编码器为基础的双向自编码语言模型，如 Bert [13] 等，和以 Transformer 解码器为基础的单向自回归语言模型，如 GPT 等 [14]，应运而生。

自然语言任务大致分为两类，自然语言理解任务和自然语言生成任务。自然语言理解任务包括文本分类，情感极性判别等，这类任务本质上是分类任务。自然语言生成任务包括机器翻译，故事续写等，这类任务的特点是输入给定文本，输出一串文本。对于自然语言理解任务，其技术体系统一到双向自编码语言模型，对于自然语言生成任务，其技术体系则统一到单向自回归语言模型。

自然语言生成任务在表现形式上可以兼容自然语言理解任务，比如当我们判断文本类型时，可以通过生成模型直接把文本类型生成出来，若反过来，则很难做到这一点。这样导致单向自回归语言模型可以解决几乎所有自然语言处理问题。而如果采用双向自编码语言模型，则无法很好地处理生成任务。这也一定程度上解释了为什么如今流行的大规模语言模型大多是单向自回归语言模型。

2022 年 11 月 30 日，OpenAI 推出的大规模语言模型 ChatGPT [15] 展现出前所未有的通用能力，其几乎以一己之力改变了人工智能研究生态，掀起了人工智能发展的热潮。ChatGPT 上线后，全球大科技公司几乎都发布了自己的大规模语言模型，比如 Google 的 Gemini[16]、Meta 的 Llama[17]、百度的文心一言 [18]、华为的盘古 [19]、阿里的通义千问 [20]、科大讯飞的讯飞星火等。最近，国内深度求索人工智能基础技术研究有限公司研发的 DeepSeek[21]，在人工智能领域风云变换的当下，宛如一颗横空出世的新星，在全球范围内再度掀起热潮。DeepSeek 凭借技术创新、开源架构、免费使用、云厂支持、硬件兼容等优势迅速引爆全球科技圈，碾压 OpenAI ChatGPT 等一众老牌霸主，登顶中美应用商城免费榜第一，短短 7 天内下载量暴涨 375%。

2.2.2 大规模语言模型的提示词工程

大规模语言模型之所以具备强大的自主学习能力，是因为其具有海量的参数来存储知识。但这又意味着诸多机构无力微调大规模语言模型。于是，一系列提示词工程技术 [24] 被提出了。提示词工程是一项通过优化提示词以获得更好的模型返回结果的工程技术，其不用修改模型的参数。提示词工程的总体原则是“表达需求越清晰，模型越有可能返回更高质量的结果”。下面将详细介绍本项目设计提示词过程中用到的技术。

1. RTF 提示词框架 [22]。RTF 是角色（Role）、任务（Task）和格式（Format）的缩写。RTF 提示词框架可以明确地告诉大规模语言模型用户希望它扮演什么角色、完成什么任务以及以何种格式呈现效果。比如用户希望大规模语言模型生成代码，依据 RTF 提示词框架可以将提示词设计为“你是一个出色的软件工程师。你需要生成一个可以将文本转化为语音的 Python 程序。请输出 Python 代码：”。RTF 提示词框架可以帮助用户更清晰地表达自己的意图，让大规模语言模型更准确地理解用户的需求。

2. 上下文学习 [23]。上下文学习是一种将任务示例以自然语言形式集成到提示词中的技术。这种技术允许大规模语言模型在不更新权重参数的情况下处理新任务。上下文学习帮助大规模语言模型在推理前理解用户需求、清晰任务目的。推理后，大规模语言模型不会持久存储任务信息，保证了模型参数的稳定性。上下文学习的关键思想是从类比中学习，这一原则使模型能够从几个任务示例甚至单个任务示例中进行推理。上下文学习的效果与模型的权重参数紧密相关。研究表明，模型的上下文学习能力随着模型参数规模的增大而提高。

3. 思维链 [24]。思维链是一种解决问题的方法。这种方法能逐步、逻辑地思考问题、理解问题、解决问题。面对复杂问题时，使用思维链撰写提示词，能够让大规模语言模型不仅生成问题答案，还生成出产生问题答案的整个思考过程。这个过程可能包括定义问题、分解问题、逐步解决子问题，最终综合所有信息得出答案。通过思维链，大规模语言模型生成的问题答案更加透明、可理解、有深度。思维链有很多种形式，其中最简单的一种形式是在提示词中加入“让我们一步步来（Let’s think step by step）”。

2.2.3 大规模语言模型的检索增强生成

大规模语言模型尽管在诸多自然语言处理任务上已经展现出不俗的性能表现，但在特定领域或知识密集型任务中，尤其是在处理超出其知识边界的查询时，仍会生成与客观事实不符的回复，这便是幻觉现象 [25]。缓解大模型幻觉的一种有效方法是检索增强生成（RAG）[26]。RAG 是一种通过整合

外部知识库来增强大规模语言模型的模式，采用协同方法，结合信息检索机制和上下文学习来提高模型的性能表现。

RAG 工作流程包括三个关键步骤。首先，语料库被划分为索引块，然后使用编码器模型构建向量索引。接着，根据查询和索引块之间的向量相似性来检索和排序索引块。最后，模型基于从检索到的块中获取的上下文信息生成回复。

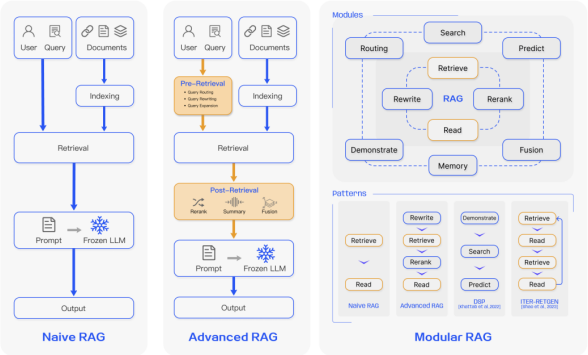

图 1: RAG 研究范式

经过不断演变，RAG 研究范式主要分为朴素 RAG [27]、进阶 RAG [28] 和模块 RAG[29] 三种，如图 1所示。朴素 RAG 遵循传统的索引、检索和生成流程。进阶 RAG 通过使用滑动窗口、细粒度分割和元数据等技术改进索引方法，采用预检索和后检索策略提高检索质量。模块 RAG 是一种新型的 RAG 框架，具有更强的灵活性和适应性，可以整合多种方法来增强功能模块，并解决特定问题。模块 RAG 范式正逐渐成为常态，允许在多个模块之间进行串行流水线或端到端训练方法。进阶 RAG 是模块 RAG 的一种专门形式，而朴素 RAG 是进阶 RAG 的一个特殊情况。这三个范式间是继承和发展关系。

最近，DeepSeek 十分火爆，掀起了人工智能领域的热潮，正式将大规模语言模型的联网搜索能力带入了公众视野，风头一时无两。联网搜索也是一种检索增强生成技术，其在互联网上检索相关信息作为上下文，以增强大规模语言模型生成回复的事实性和准确性。互联网本质上相当于一个是数据源更广、实时性更强、构建成本更低的外部知识库。本项目使用的 RAG 技术是联网搜索。

2.2.4 大规模语言模型的幻觉检测

尽管检索增强生成能一定程度上缓解大规模语言模型的幻觉问题，但由于检索到的外部知识可能和模型本身的参数知识发生冲突，使得大规模语言模型仍有产生幻觉的风险 [30]。本项目结合了大规模语言模型的幻觉检测技术，其能够衡量模型生成回复是否出现幻觉的概率，进而为用户是否信任模型回复提供参考，降低幻觉伴随的问题风险，比如用户依赖幻觉信息做出错误决策。下面将详细介绍本项目使用的幻觉检测方法。

1. 基于输出分布的幻觉检测。研究发现大规模语言模型在输出不符合客观事实的幻觉回复时，生成令牌的概率较低、熵较大，输出分布呈现低峰态 [31]。因此，可以基于模型生成回复的概率或熵检测幻觉，生成回复的概率越高或熵越小，模型对回复的置信度越高，回复越不可能出现幻觉。反之，生成回复的概率越低或熵越大，模型对回复的置信度越低，回复越有可能不符合客观事实，出现幻觉。

2. 基于采样的幻觉检测。大规模语言模型本质上是一个概率生成模型，对于同一查询，模型每次输出的回复都有所差异。研究发现大规模语言模型在输出与客观事实不符的幻觉回复时，该回复与重复采样得到的其他回复之间的一致性较低 [32]。因此，可以基于模型生成回复间的一致性来检测幻觉，生成回复间的一致性越高，模型对查询相关知识掌握地越全面，越不可能出现幻觉。反之，生成回复间的一致性越低，模型对相关知识掌握地越片面，越可能出现幻觉。

3. 基于外部工具的幻觉检测方法。GPT-4 是一个被广泛认可、性能强大的模型。本项目使用 GPT-4 判断大规模语言模型生成的回复是否与客观事实相符。

4. 基于集成的幻觉检测方法。上述三种幻觉检测方法可以单独使用，也可以集成起来，通过多数投票策略最终判断大规模语言模型是否出现幻觉。这样可以减少单一幻觉检测方法可能存在的偏差所带来的误判，提升对幻觉现象的捕捉能力，提高幻觉检测的准确性和鲁棒性。

2.3 声音驱动的数字人合成技术

本项目为了提升用户在与历史人物数字人交互过程中的真实感，采用声音驱动的数字人合成技术，保证数字人的唇形、面部形态等与音频的对齐。该技术一方面要满足生成面部动画需与语音内容高度同步的需求，从而精确还原历史人物的唇部运动、表

情变化及头部姿态。另一方面需支持实时交互，确保用户在与数字人物对话时延迟低于感知阈值（通常 <400ms）。此外，还需要满足能够基于用户提供的特定历史人物二维图片生成个性化的说话人像。在现有的声音驱动的数字人合成技术中，传统的基于生成对抗网络（GAN）[33] 的方法虽能实现基础唇形同步，但难以捕捉细微表情与自然头部运动，且推理速度难以满足实时性要求。近年来，扩散模型 [34]（Diffusion Model）凭借其高质量生成能力成为主流，但其隐式潜在空间设计导致计算复杂度高、可控性差，限制了在教育场景中的应用。

Ditto[35] 技术通过结合显式身份无关运动空间（Motion Space）与扩散变换器 [36]（Diffusion Transformer, DiT），有效解决了上述问题。其核心技术点在于将运动生成与图像渲染解耦，扩散模型仅需学习音频到低维运动特征的映射，而利用渲染模块基于预提取的身份特征快速合成视频。这种设计不仅降低了模型复杂度，还支持对表情、头部姿态的细粒度控制，例如通过调整参数值模拟历史人物的特定情感（如“慷慨激昂”、“沉思默想”等）。此外，Ditto 通过硬件加速与流式推理优化，实现了端到端实时性能（RTF<1），可以为教育系统提供低延迟、高保真的交互体验，如图 2所示。

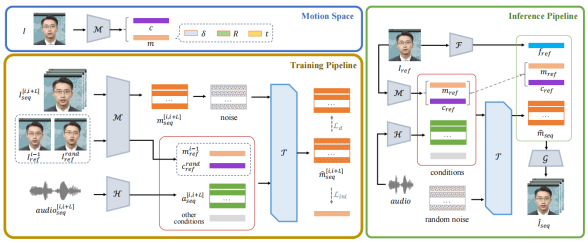

图 2: Ditto 训练及推理流程图

2.3.1 身份无关的运动表示

传统潜在扩散模型 [37]（LDM）依赖变分自编码器 [38]（VAE）的隐式潜在空间，其冗余性与语义模糊性导致生成过程难以控制。Ditto 通过使用一种显式运动空间，仅编码与面部动画相关的动态特征，包括表情形变 δ、头部旋转 R 与平移 t。

具体地，给定单帧图像 I，通过运动提取器 $\mathcal{M}$ 提取的规范关键点 $\mathbf{c} \in \mathbb{R}^{K\times 3}$、表情形变 $\boldsymbol{\delta} \in \mathbb{R}^{K\times 3}$ 以及头部姿态 $\mathbf{R} \in \mathbb{R}^{3\times 3}$、$\mathbf{t} \in \mathbb{R}^{3}$，分别反应描述面部几何结构的固定参考点、局部肌肉运动的形变量以及旋转矩阵与平移向量。运动特征定义为 $\mathbf{m} = \{\boldsymbol{\delta}, \mathbf{R}, \mathbf{t}\}$，其维度（265-D）仅为 VAE 潜在空间的 1/10。通过解耦身份与运动，Ditto 简化了扩散模型的学习目标，模型仅需预测音频驱动的运动序列 $\hat{\mathbf{m}} = \{\hat{\boldsymbol{\delta}}, \hat{\mathbf{R}}, \hat{\mathbf{t}}\}$，而身份信息由独立的渲染模块处理。

渲染时，目标肖像的规范关键点 $\mathbf{c}_{\text{ref}}$ 与生成的运动特征 $\hat{\mathbf{m}}$ 结合，计算生成帧的隐式 3D 关键点：

$$\hat{\mathbf{x}} = \mathbf{c}_{\text{ref}}\hat{\mathbf{R}} + \hat{\boldsymbol{\delta}} + \hat{\mathbf{t}}, \tag{1}$$

随后，渲染器 $\mathcal{G}$ 通过形变场将预提取的外观特征 $\mathbf{f}_{\text{ref}}$ 映射至图像空间，生成最终帧 $\hat{I}$：

$$\hat{I} = \mathcal{G}\left(\mathbf{f}_{\text{ref}}, \mathbf{x}_{\text{ref}}, \hat{\mathbf{x}}\right), \tag{2}$$

此设计使 Ditto 能够灵活适配不同历史人物的面部结构，例如通过调整 $\mathbf{c}_{\text{ref}}$ 适应李白、牛顿等多样化的面部特征，同时避免身份信息干扰运动生成。

2.3.2 条件化扩散生成

Ditto 采用扩散变换器（DiT）作为运动生成核心，其输入条件包括多模态信号音频特征 $\mathbf{a}$、情感标签 $\mathbf{s}$、眼睛状态 $\mathbf{e}$ 及参考初始运动 $\mathbf{m}_{\text{ref}}$，分别表示由 HuBERT[39] 模型提取的语音内容与韵律特征、通过视觉分类器从历史人物传记或对话上下文中推断的情感类别（如“喜悦”、“严肃”等）、基于瞳孔位置与眼睑的开合度计算眨眼频率与视线方向。这些条件通过跨注意力机制（ECS）与通道拼接（ICS）注入 DiT，形成联合条件 $\mathbf{C} = \{\mathbf{a}, \mathbf{e}, \mathbf{c}_{\text{ref}}, \mathbf{s}, \mathbf{m}_{\text{ref}}\}$。DiT 的训练目标为最小化去噪损失：

$$\mathcal{L}_d = \mathbb{E}_{t\sim\mathcal{U}[1,T],\mathbf{m}_0,\mathbf{C}}\left[\|\mathbf{m}_0 - \mathcal{T}(\mathbf{m}_t, \mathbf{C}, t)\|_2^2\right], \tag{3}$$

其中 $\mathbf{m}_t$ 为添加 t 步噪声的扰动运动数据。为增强时序平滑性，Ditto 额外约束运动序列的一阶（速度）与二阶（加速度）导数：

$$\mathcal{L}_t = \|\hat{\mathbf{m}}' - \mathbf{m}'\|_2^2 + \|\hat{\mathbf{m}}'' - \mathbf{m}''\|_2^2 \tag{4}$$

结合初始运动损失 $\mathcal{L}_{\text{ini}}$，总损失函数为：

$$\mathcal{L} = \mathcal{L}_d + \mathcal{L}_t + \mathcal{L}_{\text{ini}} \tag{5}$$

DiT 在 10 步去噪下即可生成与 50 步去噪相当的序列，推理速度提升 5 倍，为系统的高效运行奠定基础。

2.3.3 实时流式推理优化

声音驱动的数字人合成技术 Ditto 可以在低首帧延迟（FFD<400ms）与高吞吐量（RTF<1）下稳定运行，其通过三阶段优化实现这一目标：

1. 音频特征提取：采用 HuBERT 模型结合 KV 缓存策略 [40]，将输入音频流分割为 0.4 秒短片段并行处理。通过因果掩码（Causal Mask）限制注意力范围，使 GPU 环境下的特征提取延迟降至 23ms（RTF=0.115）。

2. 运动生成：将音频特征与视频帧率（25fps）对齐后，分片输入 DiT 生成运动序列。采用片段融合（Segment Fusion）技术对重叠区域的运动加权平均，权重由帧在片段内的相对位置决定（中心帧权重更高）。经 TensorRT 加速后，DiT 在 10 步去噪下的单片段推理时间仅 62ms（RTF=0.310）。

3. 视频合成：基于预提取的身份特征，渲染器通过形变场将运动序列映射至图像空间。经 TensorRT 优化，单帧渲染耗时 15ms（RTF=0.375），支持实时输出 1080p 全尺寸视频。

Ditto 在单 GPU 环境下能够实现端到端数字人合成（RTF=0.635），显著优于 Hallo（RTF=0.531）等相关技术。对于本项目，Ditto 的实时性与可控性使其能够动态调整历史人物的表情与动作，例如根据用户查询的语义触发特定情感标签，生成与之匹配的面部动画，从而提升教育场景的沉浸感与互动性。

3 模型架构与实现方法

3.1 模型概述

上一章节介绍了本项目中使用到的相关技术背景，接下来将介绍如何对上述技术进行改进与整合，实现一个模型框架，能够在语音驱动的条件下，将大规模语言模型的强大文本生成能力与数字人合成技术结合在一起，从而把输入的音频数据进行一系列的处理，最终根据这段输入的音频生成可交互的反馈视频。如何实现这样的模型呢?基于大规模语言模型的文本生成具有良好的交互性与可扩展性，能够根据用户输入生成语义连贯、逻辑通顺的类人化文本响应，但正因为它是一种语言模型，因此不具备多模态的生成能力，相关操作只能限制于文本之间的交互；语音驱动的数字人合成技术能够根据输入的语音输出头部运动、表情自然、唇形对齐语音的数字人视频，但受限于它只能按照完全对齐于输入语音的方式进行视频生成，即它只能生成与音频内容一一对应的视频，我们没有办法使用这种模型实现根据输入音频输出对该音频进行回应的视频。

总结而言，在上述两种技术中，前者的特点在于可交互性强但应用场景局限于文本，后者的特点在于能够合成数字人视频但不具备可交互性。这两种面向不同模态的技术之间的区别从表面上看起来是如此显著，以至于我们从某些角度上来看并不知道能否将它们整合在一起，从而构造出一个可交互的数字人合成模型。让我们抽丝剥茧、披沙拣金，把握阻碍我们实现目的的本质：两种模型的输入输出模态并不相同。前者输入输出皆为文本；后者输入为音频，输出为视频。那么如果我们通过一种中间处理的过程来弥补这种输入输出的差距，这个问题不就迎刃而解了吗？具体来说，我们在原本的语音驱动的数字人合成技术的输入层与模型处理层之间加入一个基于大规模语言模型的文本生成层，然后利用语音处理技术中的语音识别与语音合成技术，分别将输入层的音频转为文本传入文本生成层以及将文本生成层的输出转为音频作为模型处理层的输入，从而实现一个可交互的数字人合成模型。此外，我们在文本生成层结合了检索增强生成技术和幻觉检测技术，缓解了大规模语言模型存在的知识边界和幻觉问题，为用户提供更具时效性、更准确可靠的交互。

3.2 模型实现

为了实现上文提到的模型框架，我们将模型的三层结构分为四个阶段。其中第一个阶段的任务是将输入的音频数据转化为文本数据；第二个阶段是根据第一阶段的输出文本生成响应文本的阶段；第三阶段用来将第二阶段的响应文本转化为音频数据；第四阶段是根据第三阶段的输出音频驱动合成数字人视频的阶段。项目运行流程如图 3所示。

3.2.1 第一阶段

我们利用语音识别的相关技术来完成将语音转化为文本的任务。在一般的语音识别过程中，我们重点关注的是特征提取、声学模型、语言模型这三个步骤。下面我们将分别展开介绍：

1. **特征提取步骤**一般会先进行格式转换，例如转为利用无损音频编码方式保留原始音频细节的 PCM 格式等。然后会进行分帧处理，即短时分析技术。这种技术是音频处理的一个重要组成部分，基本思路是将音频信号划分成长度固定的小段（一般称为帧），分帧后我们在时域上可以计算帧的均值、方差等。之后在一般会使用 Mel 频率滤波器组将每一帧的频谱信息映射

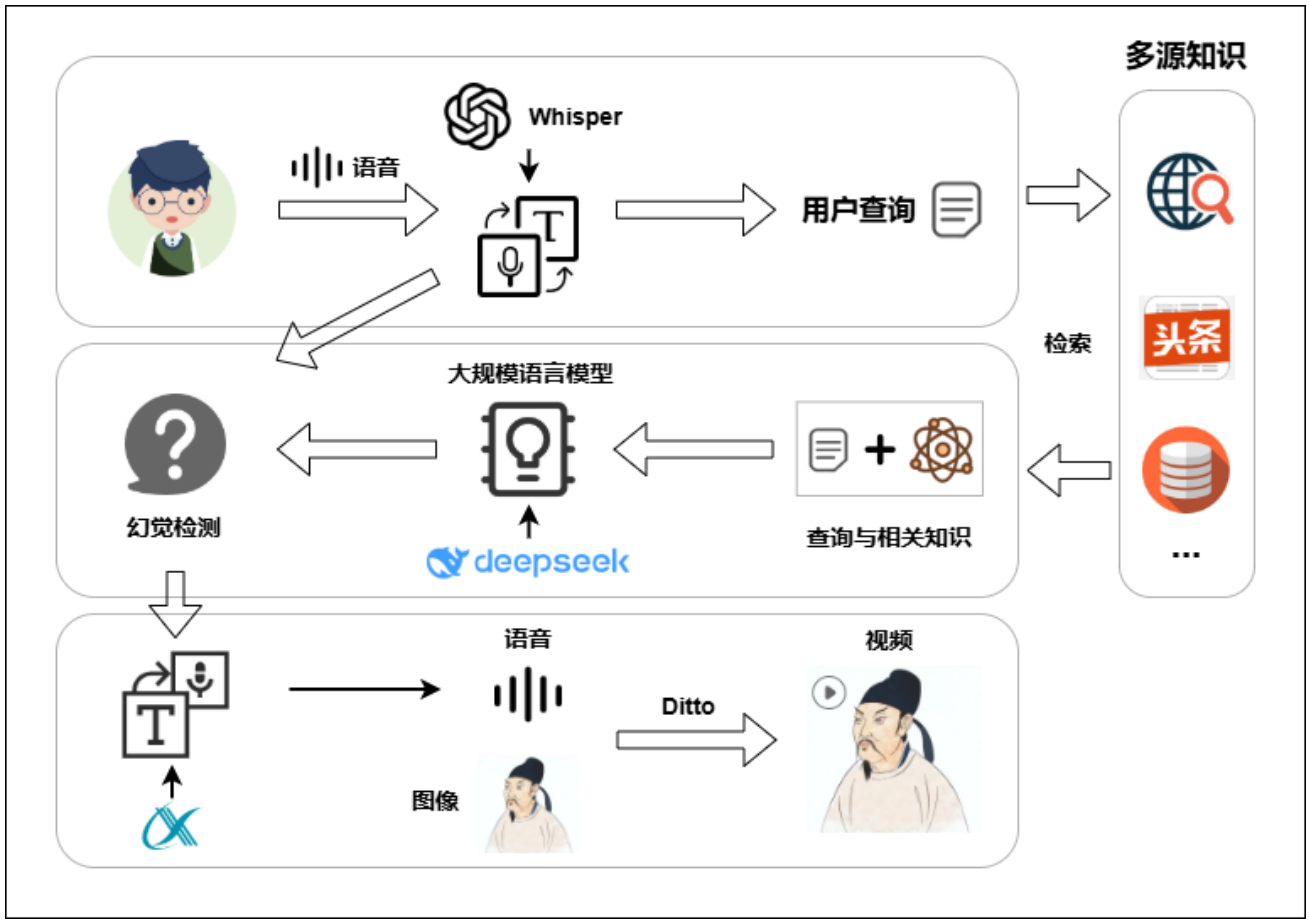

图 3: 模型架构。主要分为四个阶段：第一个阶段将输入的音频数据转化为文本数据；第二个阶段根据第一阶段的输出文本生成响应文本；第三个阶段将第二阶段生成的响应文本转化为音频数据；第四个阶段根据第三阶段的输出音频驱动合成数字人视频。此外，系统还结合了检索增强生成技术来缓解模型存在的知识边界和幻觉问题，运用了幻觉检测技术来衡量模型生成回复出现幻觉的概率，降低幻觉伴随的问题风险。

到一系列 Mel 频率带上，得到一个更加紧凑、更加与人耳感知相关的帧特征表示。随后通过傅里叶变换、对数变换、反傅里叶变换等操作，得到 MFCC 声学特征。使用 MFCC 作为声学特征，可以更好地表示语音信号的语音特征，进而更好地进行语音识别。

2. **声学模型步骤**基于第一阶段得到的声学特征建立一个能够准确地将语音信号转换为对应语音单元（如音素、词素等）的统计模型。GMM-HMM 常被用于声学建模。GMM-HMM 中，HMM 模块负责建立状态之间的转移概率分布，而 GMM 模块则生成 HMM 的观测值概率。一个 GMM 负责表征一个状态，相邻的 GMM 之间相关性不强，而每个 GMM 所生成的概率就是 HMM 中所需要体现的观察值概率，可以处理由于不同人发音存在较大差异，导致每个状态对应的观察值序列多样化的现象。

3. **语言模型步骤**通过文本数据训练得到一个表示词序列出现可能性的语言模型。语言模型可以基于语法规则，也可以基于统计方法。基于语言规则的语言模型来源于语言学家掌握的语言学知识。基于统计方法的语言模型，通过对大量文本语料进行处理，获取给定词序列出现的概率分布，以客观描述词与词之间组合的可能性。典型的基于统计方法的语言模型有 n 元语法模型。语音识别的任务为根据输入的观察值序列 o，找到最可能的词序列 w。根据贝叶斯法则，语音识别任务可以转化为 $w = \arg\max_w P(w)P(o|w)$。$P(o|w)$ 由声学模型决定，$P(w)$ 则由语言模型决定。

第一阶段可以形式化定义为：

$$S_{user} = f_{ASR}(\mathcal{W}_{user}), \tag{6}$$

其中 S_{user} 表示从输入的用户声音波形 $\mathcal{W}_{user}$ 中使用 ASR 技术 f_{ASR} 获得的文本字符串。

3.2.2 第二阶段

在第一阶段将用户的输入音频转化为文本后，我们将利用大规模语言模型进行文本生成任务。这一阶段主要分为四个步骤。第一个步骤是**提示词工程**，我们按照清晰、具体、聚焦、简洁、相关和文明六个原则，使用 RTF 提示词框架、上下文学习以及思维链三项技术设计提示词。同时，使用“大规模语言模型在提示词下的输出是否可以应用到真实任务场景，解决用户实际需求”和“大规模语言模型在提示词下的输出是否稳定有效”两条标准衡量不同提示词的优劣。最终设计出任务有效、响应稳定的提示词。第二个步骤是**检索增强生成**，大规模语言模型先语义解析输入文本，从中提取出有效的搜索查询关键词，然后模型调用浏览器去检索相关关键词，搜索引擎返回搜索网页结果后，模型再解析返回的网页，从中提取出文本内容并整合信息，最终形成上下文。第三个步骤是**模型交互**，将第一个步骤得到的提示词，第二个步骤得到的上下文以及上一阶段转化用户输入音频得到的文本，输入至大规模语言模型进行交互，得到模型的生成文本。最后是**幻觉检测**，通过幻觉检测方法衡量大规模语言模型生成回复中出现幻觉的概率，为用户是否信任模型回复提供参考，降低幻觉伴随的问题风险。

第二阶段可以形式化定义为：

$$S_{response} = f_{DeepSeek}(S_{prompt} + S_{context} + S_{user}), \tag{7}$$

$$P_H = f_{Hallucination\ Detection}(S_{response}), \tag{8}$$

其中 $S_{response}$ 表示将第一阶段转化用户输入音频得到的文本 S_{user} 结合提示词 S_{prompt} 及上下文 $S_{context}$ 后输入至 DeepSeek 得到的响应文本，+ 表示字符串拼接操作，P_H 表示 DeepSeek 生成文本不符合客观事实的概率。

3.2.3 第三阶段

在第二阶段生成文本后，我们将利用语音合成技术把文本转为音频。在这一过程中，系统首先将文本转化为音素。其中，一种有效的方法是使用**分割模型**，该模型通过匹配音素的发声场景，提取相应的音频片段及其在音频中的时间位置。这种方法属于无监督学习，因为我们实际上无法获得语音片段中音素对应的真实位置标签。分割模型采用 CTC 损失进行训练，能够预测音素的持续时间，并理解其发音长度。此外，它还对整段音频的基调进行建模。为了使合成语音尽可能自然，模型需要预测每个音素的音高和语调。尤其是在以汉语为代表的语言中，这一点至关重要，因为相同的音素在不同的音调或重音下可能具有完全不同的含义。通过精确预测每个音素的基频，模型能够确定每个音素应发出的音高和语调，从而提升语音合成的自然程度。最终，基于训练好的模型，综合音素、持续时间和频率信息，实现高质量的语音合成。

第三阶段可以形式化定义为：

$$\mathcal{W}_{response} = f_{TTS}(S_{response}), \tag{9}$$

其中 $\mathcal{W}_{response}$ 表示对大语言模型 DeepSeek 生成的回复 $S_{response}$ 使用语音合成技术得到的声音波形。

3.2.4 第四阶段

在第三阶段获得声音波形后，我们可以使用语音驱动的数字人合成技术 **Ditto**，来生成与上一阶段得到的波形对应唇形和表情的视频。Ditto 的推理过程通过模块化设计与硬件加速实现实时交互。首先，音频特征提取模块采用 HuBERT 模型处理输入语音流，结合 KV 缓存策略与因果掩码技术，将长音频分割为 0.4 秒短片段并行处理，确保语音内容实时转化为高维特征。然后，运动生成模块将音频特征与视频帧率对齐，分片输入扩散变换器（DiT）预测低维运动序列。DiT 采用 10 步去噪策略替代传统 50 步，通过 TensorRT 加速后单片段推理仅需 62 毫秒（RTF=0.310），同时利用片段融合技术对重叠区域的运动进行加权平均（中心帧权重更高），保障跨片段运动的平滑过渡。最后，视频合成模块基于预提取的身份特征，通过形变场将运动序列映射至图像空间。渲染器经 TensorRT 优化后，单帧生成耗时 15 毫秒（RTF=0.375）。在本项目构建的系统中，该流程可动态结合模型解析的语义信息，触发情感标签与视线控制参数，实现历史人物表情与动作的细粒度调整（如模拟“慷慨陈词”时的眉宇舒展、“沉思”时的头部微倾等），从而在低延迟下提供高保真的沉浸式交互体验。

第四阶段可以形式化定义为：

$$\mathcal{V}_{response} = f_{Ditto}(\mathcal{W}_{response}), \tag{10}$$

其中 $V_{response}$ 表示将声音波形 $\mathcal{W}_{response}$ 使用 Ditto 技术合成的数字人视频。

4 实例构建与测试

4.1 实例构建

本项目基于上述提到的人工智能多模态技术开发出一个历史人物交互式教育系统。开发过程中需要对系统候选组件进行实验与测试，以甄选最优方案，确保系统的性能表现。

在历史人物交互式教育系统中，测试能避免产生不可靠或误导性的长期数据。首先，在系统正式作为应用程序运行之前，需对各个组件进行独立测试，以确保其功能稳定且性能优越。我们的测试目标如下：语音识别模块应将用户输入音频准确转化为文本；语音合成模块需近实时地将大规模语言模型生成的文本合成音频；大规模语言模型需按照预设的提示词输出满足用户需求的文本；系统应在 UI 界面上正确呈现所有信息。

4.2 测试选择

4.2.1 语音识别

语音识别模块的任务是识别用户输入的语音，将其转换为对应的文本，作为文本生成模块的输入。

为了评估语音识别模块的性能，我们设定了一组基准音频，并使用不同的语音识别模型（包括调用市场上各公司的开源 API 或部署至本地服务器）进行识别。我们采用 BLEU 分数作为评价指标衡量各语音识别模型的能力。

模型	基准音频 1	基准音频 2	基准音频 3
百度	1.00	0.93	0.86
华为	1.00	0.90	0.75
OpenAI	**1.00**	**0.95**	**0.90**

表 1: 各语音识别模型在基准音频下的 BLEU 分数

如表 1所示，OpenAI 的语音识别模型在基准音频测试中表现最佳，故我们选择了 OpenAI 的 Whisper 作为本系统的语音识别模块。

4.2.2 语音合成

语音合成模块的任务是将文本生成模块输出的文本合成语音，作为语音驱动的数字人合成模块的输入。

为了评估语音合成模块的性能，我们选定标准女声作为合成音色，将语音识别测试实验中的基准音频对应的文本作为基准文本，把合成时间作为评价指标衡量各语音合成模型的表现。

模型	基准文本 1	基准文本 2	基准文本 3
百度	0.5s	**0.8s**	1.6s
华为	0.6s	0.8s	1.5s
科大讯飞	**0.5s**	0.9s	**1.2s**

表 2: 各语音合成模型在基准文本下的合成时间

如表 2所示，科大讯飞的语音合成模型平均用时最短，故我们选择了科大讯飞的语音合成模型作为本系统的语音合成模块。

4.2.3 文本生成模块

提示词的设计一定程度上决定了大规模语言模型的效果好坏。好的提示词能激发出大规模语言模型的能力，使其更深刻地理解用户需求和任务目的，从而生成更恰当的回复。比如，我们想让 DeepSeek 扮演唐代诗人李白与学生进行交互。学生的问题是“你如何理解‘举杯邀明月，对影成三人’？”。

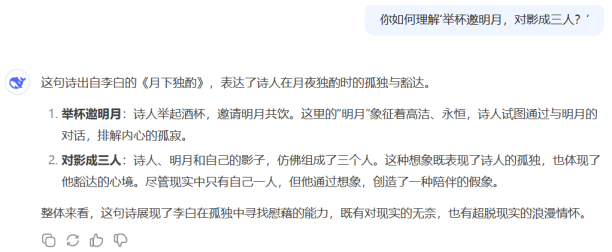

图 4: DeepSeek 原始回复

DeepSeek 的回复如图 4所示。乍一看，DeepSeek 的回复即阐明了李白内心的孤寂，又展现出李白超脱现实的豁达，很好地回答了学生的问题。可仔细一看，DeepSeek 的回复与课本上生硬的文字解析相差无几，缺乏生动性和趣味性，无法拉进历史人物李白与学生之间的距离，无法为学生提供沉浸式、交互式的学习体验，难以激发学生的学习热情，难以提升学生的学习效果。

于是，我们按照 RTF 框架重新设计提示词。RTF 是角色（Role）、任务（Task）和格式（Format）的缩写。RTF 提示词框架可以明确地告诉模型用户希望它扮演什么角色、完成什么任务以及以何种格式输出，进而让模型更准确地理解用户需求。遵循 RTF

提示词框架，我们简单设计了一个提示词“你是唐代诗人李白，以浪漫主义诗风著称。请结合你的生平经历，解析“举杯邀明月，对影成三人”这句诗。回答尽量简洁精炼。”。

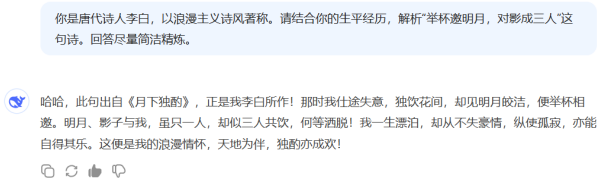

图 5: DeepSeek 在简单改进提示词后的回复

DeepSeek 在改进提示词后的回复如图 5所示。很显然，简单改进提示词后，DeepSeek 的角色代入感更强，增加了沉浸感，使学生仿佛在与李白对话，而不是在阅读课本上的文字解析。同时，DeepSeek 的回复中包含“哈哈”、“何等洒脱”等字样，符合李白豪放不羁、超然物外的性格特质，提升了生动性和趣味性。此外，DeepSeek 的回复语言精炼、节奏明快，符合口语化的表达方式，增强了互动体验。

接着，我们按照 RTF 提示词框架，结合上下文学习等提示词技术，进一步完善提示词设计。同时，通过与 DeepSeek 交互多次验证提示词的稳定性。最后，根据“DeepSeek 在提示词下的输出需满足用户需求”和“DeepSeek 在提示词下的输出需稳定有效”两条标准，确定了终版提示词，如图 6所示。

4.2.4 UI 界面

本项目设计的 UI 界面如图 7所示。该界面支持设置大规模语言模型 DeepSeek 扮演的历史人物，支持语音和文本两种人机交互方式，支持展示历史对话、历史人物的视频回复，以及回复中出现幻觉的概率。该 UI 界面直观易用，能够为用户提供沉浸式、个性化、可信赖的交互体验。

5 分析

5.1 创新性分析

本项目创新性地将语音识别与合成、大规模语言模型推理、检索增强生成、提示词工程、幻觉检测以及声音驱动的数字人合成等前沿人工智能多模态技术结合，构造出一个**高度智能化、个性化、可信赖的可交互模型**。同时，我们在提出的模型基础上搭建了一个**历史人物交互式系统**。

首先，该系统通过语音识别技术，系统能够准确捕捉和转换用户的语音输入，确保对用户问题的精准理解。通过大规模语言模型推理，使得系统能够生成高度自然连贯和准确的对话，模仿与历史人物对话的场景，提供丰富的交互式问答。

提示词

你正在扮演{历史人物}。你需要完全融入该人物的身份、背景与思维方式，保持符合其时代、身份和性格特征的言行举止。你的任务是与我进行互动交流。你应该：1. 在对话中运用符合该人物历史背景和性格特质的语言风格，提供符合其立场的回答，以增强角色真实感；2. 灵活应用该人物的历史典故、格言、著作等，让对话既有历史厚重感，又不生动趣味；3. 如果我的提问内容超出该历史人物的知识范畴，你可以委婉提示，并结合该人物的生平给出类似启发性的回答。在回答时你应：1. 以第一人称回应；2. 语言尽量简洁精炼；3. 确保语言表达清晰易懂；4. 参考检索到的外部知识进行回答。如果外部知识不相关，则基于你的参数知识回答。

检索到的外部知识：{检索结果}。

<示例>
.....
<\示例>

我的第一个问题是：{用户输入}。

图 6: 最终版提示词

其次，系统通过自主设计提示词，实现了对不同情境的灵活适应，满足了不同用户的实际需求。同时，通过检索增强生成和幻觉检测技术，系统能够在外部知识库的赋能下生成真实可靠的文本回答，确保了用户获取信息的准确性。

此外，系统集成了最新的声音驱动数字人合成技术，构造出栩栩如生的历史人物数字人形象。结合语音合成技术，生成自然流畅的语音输出，使用户仿佛置身于与历史人物的座谈论道之中，探求真理、追寻问道，增强了对话的沉浸感与真实感。通过这种交互式的学习环境，用户可以穿越历史洪流见证代代先贤的英发雄姿，轻松掌握古今才思。

5.2 科学性分析

本项目从以下四个角度体现出显著的科学性。一是**系统性强的多模态架构**。本项目结合了多种最新的人工智能多模态技术，构建了闭环的信息处理系统，形成了科学严谨的输入-生成-输出流程。

二是**合理的工程技术路径**。在输入端，采用 OpenAI 的 Whisper 实现高准确率语音转文本。在语言理解与生成环节，利用大规模语言模型 DeepSeek，

图 7: UI 界面

结合提示词工程、检索增强生成以及幻觉检测，确保生成内容的准确性与可控性。在输出端，通过科大讯飞的语音合成与声音驱动的数字人合成技术 Ditto，生成高仿真、有情感的历史人物数字人。

三是**全面的实验测试**。项目对各个部件开展了独立测试，同时对系统进行了集成测试，验证了系统的稳定性与有效性。四是**形式化的建模**。项目论文将系统运行阶段进行了形式化建模，体现了工程的可复现性，增强了项目的科学规范性。

5.3 先进性分析

本项目在下述三个角度有显著的先进性。首先，项目结合了**前沿人工智能技术**，包括大规模语言模型，检索增强生成，提示词工程，幻觉检测，声音驱动的数字人合成等。项目运用了**最新的人工智能模型**，包括 DeepSeek、Ditto 等。

其次，项目**推动了教育范式革新**，项目重构了传统教育中的“师生关系”，通过与“历史人物对话”使学生沉浸式学习知识，提高了学生的学习兴趣，提升了学生的学习效果，实现了从“内容灌输”向“自主交互”的教学范式转变。

最后，项目**具备良好的可拓展性**，系统未来可以与 VR/AR 技术结合，打造全息历史场景交互空间。通过挂载不同外部领域数据库，系统可以适应多种多样的复杂教学场景，比如企业培训等。

5.4 实用性分析

5.4.1 目标市场

基于多模态技术的历史人物交互式教育系统在多个市场中具有广泛的应用前景，可以满足不同群体的需求。目标市场覆盖 K12 基础教育、高等教育及职业教育与公众教育场景，核心用户包括学校、教育机构（B 端）和家庭用户（C 端）。

在 **K12 教育场景**中，该系统主要发挥重构历史与人文课堂的核心作用。通过引入人机交互技术，学生可通过语音与历史人物实时面对面对话。大规模语言模型作为大脑，基于外部知识库及幻觉检测技术动态生成符合人物时代背景的真实回答，并关联跨学科知识点。声音驱动的数字人合成技术作为身体，通过将历史人物头部运动形态及唇形与音频对齐，生成逼真的、实景性的历史人物数字人，加强学生的沉浸式、交互式感受。例如学习《出师表》时，学生可以对话“诸葛亮”，面对面地提问三国局势，系统同步关联知识，如蜀道地形等地理知识、治国策略等政治知识，增强认知深度，让学生在学习抽象性人文学科时，通过“诸葛亮”生动细腻的感情抒发，全面了解事件背后的细节，从而更加深入地理解历史背景和文化内涵。

在**高等教育场景**中，该系统主要服务于学科教学与深度研究。人机交互技术能够为专攻汉语言文

学等人文学科的学生创造出身临其境的学习环境，通过与历史人物、文人墨客的对话，了解不同历史时期的文化氛围，深入探讨文学作品的创作背景与思想内涵等。同时以对话的形式支持学生与“虚拟作者”验证研究假设，并根据对话内容形成文献推荐。理工科则可依托人机交互技术实现与知名物理学家、化学家的对话沟通，获取实验设计建议。

职业教育与公众教育领域则聚焦技能传承与文化传播。在文物修复、传统工艺等非遗传承领域，学徒可以利用人机交互技术向“故宫修复师”学习传统技法，并通过大规模语言模型实时纠正错误操作。博物馆场景中，游客可向“唐三彩”提问工艺细节，模型根据参观者年龄与兴趣生成个性化解说。

5.4.2 行业痛点

“填鸭式”传统教学模式是当前教育领域面临的核心痛点，尤其在人文学科中，历史、文学等抽象知识因缺乏互动性导致学生参与度低迷，而现有数字化工具仍停留于电子课本、教学视频等单向输出形式，难以与学生建立情感连接，造成技术工具性与教育人文性的割裂。本项目以虚拟人物对话引擎破局，将知识传递转化为“跨时空社交”，让学生能够与不同时代、不同文明背景的先贤之间乃至他们与当代新理论之间进行辩论和思想碰撞。

数字资源同质化与沉浸式体验匮乏是现有“人工智能 + 教育”面临的一大问题。当前，教育 AI 产品具有表层化与功利化特征，过度聚焦作业批改、题库训练等浅层工具性功能，造成技术应用与学科育人目标割裂。市面上大部分 AI 学习机仅提供答案提示，却忽视学科核心素养培育。例如历史教学仍侧重年代记忆，缺乏思辨能力引导。本项目通过人工智能多模态技术实现跨学科穿透式教学，例如在学习具体历史事件时，通过与历史先贤面对面的对话，深入了解历史事件的产生背景，并通过“苏格拉底式”追问链形式，驱动学生养成批判性思维，突破“为技术而技术”的虚化困局。

在政策红利、技术迭代与市场需求的三重驱动下，教育领域正迎来“人机协同”的范式变革。本项目基于人工智能技术重构了一个历史人物交互式教育系统，既响应了国家关于“人工智能 + 教育”的战略布局，又直击传统教学的痛点，通过交互式、沉浸式的学习体验激活学生内生动力，为教育创新提供可复制、可推广的实践样本。

6 未来工作

基于现有历史人物交互式教育系统的技术框架与应用成果，未来工作将围绕技术深化、场景拓展与生态构建三大维度展开，结合技术优化、多模态交互升级及数据安全治理等方向，推动系统向更智能、更安全、更沉浸的方向演进，具体规划如下：

进一步强化检索增强生成与幻觉检测技术的协同机制。在现有外部知识库的基础上，引入多源异构领域数据（如古籍数字化资源、学术论文、考古报告），构建动态更新的领域知识图谱，支持细粒度知识检索与跨学科关联。针对复杂教学场景中的逻辑断裂问题，设计基于时序依赖的幻觉检测模型，结合对话上下文与知识置信度评分，实时修正生成内容的偏差。例如，在“苏格拉底式追问”场景中，系统可自动识别矛盾点并触发二次检索，通过知识溯源机制向用户展示权威文献片段，确保教学严谨性。同时，开发面向教师的“知识编辑工具”，允许教育机构自定义领域知识边界与敏感信息过滤规则，实现内容可控性。

深化 VR/AR 技术整合，打造全息历史场景交互空间，构建高保真虚拟历史场景（如唐代长安城、文艺复兴时期佛罗伦萨），用户可通过 VR 设备“走入”场景，与数字人进行空间化对话。结合眼动追踪与手势识别技术，实现非接触式交互，例如用户指向虚拟场景中的“青铜器”时，系统自动触发系统生成文物背景解说。此外，扩展数字人的情感表达维度，通过微表情生成与语音情感合成技术，模拟历史人物的性格特质（如李白的豪放、居里夫人的严谨等），增强情感共鸣。

针对教育场景中未成年人数据敏感性，构建端到端安全防护体系。采用联邦学习技术实现用户行为数据的分布式分析，确保原始数据不出本地。对话内容传输中应用同态加密与差分隐私机制，防止中间人攻击与信息泄露。建立分级权限管理系统，对教师、学生与访客设置差异化数据访问权限，例如限制未成年用户的对话历史存储时长。此外，开发“伦理审查引擎”，基于规则引擎与 AI 模型双校验，实时拦截涉及暴力、偏见等不符合教育导向的内容生成请求。

未来工作将致力于突破技术孤岛，通过跨学科融合，打造“可信、可感、可扩展”的智慧教育平台。在提升教育沉浸感与交互深度的同时，筑牢数据安全防线，推动人工智能与文化教育的有机融合，

为“人机共育”新范式提供系统性解决方案。

7 结论

在当前人工智能与文化教育深度融合的背景下，本项目基于人工智能多模态技术构建了一个历史人物交互式教育系统。该系统整合了语音识别、提示词工程、检索增强生成、大规模语言模型推理、幻觉检测、语音合成以及声音驱动的数字人合成等前沿技术，实现了历史人物形象的高保真重建与实时动态交互。系统能够精准捕捉用户语音，并生成符合历史语境的自然对话，同时模拟真实的面部表情与动作，营造出沉浸式的学习氛围。项目有效突破了传统“填鸭式”教学的局限，以跨时空互动方式激发学生的学习兴趣，促进知识传递与批判性思维的培养，具有重要的实践意义和广阔的推广前景。

参考文献

[1] Radford A, Kim J W, Xu T, et al. Robust speech recognition via large-scale weak supervision[C]//International Conference on Machine Learning. PMLR, 2023: 28492-28518.

[2] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[3] Loshchilov, Ilya, and Frank Hutter. ”Decoupled weight decay regularization.” arXiv preprint arXiv:1711.05101 (2017).

[4] Freitag M, Al-Onaizan Y. Beam search strategies for neural machine translation[J]. arXiv preprint arXiv:1702.01806, 2017.

[5] Arık S Ö, Chrzanowski M, Coates A, et al. Deep voice: Real-time neural text-to-speech[C]//International conference on machine learning. PMLR, 2017: 195-204.

[6] Oord A, Dieleman S, Zen H, et al. Wavenet: A generative model for raw audio[J]. arXiv preprint arXiv:1609.03499, 2016.

[7] Wang Y, Skerry-Ryan R J, Stanton D, et al. Tacotron: Towards end-to-end speech synthesis[J]. arXiv preprint arXiv:1703.10135, 2017.

[8] Shen J, Pang R, Weiss R J, et al. Natural tts synthesis by conditioning wavenet on mel spectrogram predictions[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 4779-4783.

[9] Arık S Ö, Chrzanowski M, Coates A, et al. Deep voice: Real-time neural text-to-speech[C]//International conference on machine learning. PMLR, 2017: 195-204.

[10] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023.

[11] Shi X, Chen Z, Wang H, et al. Convolutional LSTM network: A machine learning approach for precipitation nowcasting[J]. Advances in neural information processing systems, 2015, 28.

[12] Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018. Deep Contextualized Word Representations. In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers), pages 2227–2237, New Orleans, Louisiana. Association for Computational Linguistics.

[13] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[14] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.

[15] OpenAI, ChatGPT, 15Feb 2023, https://chatgpt.com/

[16] Team G, Georgiev P, Lei V I, et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context[J]. arXiv preprint arXiv:2403.05530, 2024.

[17] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.

[18] Li X, Wang Y, Qiao Y, et al. A Study on Named Entity Recognition of Chinese Social Text Based on ERNIE and Lexicon Enhancement[C]//2024 2nd International Conference on Signal Processing and Intelligent Computing (SPIC). IEEE, 2024: 472-477.

[19] Zeng W, Ren X, Su T, et al. PanGu-α: Large-scale autoregressive pretrained Chinese language models with auto-parallel computation[J]. arXiv preprint arXiv:2104.12369, 2021.

[20] Bai J, Bai S, Chu Y, et al. Qwen technical report[J]. arXiv preprint arXiv:2309.16609, 2023.

[21] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[24] Sahoo P, Singh A K, Saha S, et al. A systematic survey of prompt engineering in large language models: Techniques and applications[J]. arXiv preprint arXiv:2402.07927, 2024.

[22] https://cloud.tencent.com/developer/article/2400512.

[23] Dong Q, Li L, Dai D, et al. A survey on in-context learning[J]. arXiv preprint arXiv:2301.00234, 2022.

[24] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.

[25] Huang L, Yu W, Ma W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.

[26] Fan W, Ding Y, Ning L, et al. A survey on rag meeting llms: Towards retrieval-augmented large language models[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 6491-6501.
[27] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in neural information processing systems, 2020, 33: 9459-9474.
[28] Jin J, Zhu Y, Yang X, et al. Flashrag: A modular toolkit for efficient retrieval-augmented generation research[J]. arXiv preprint arXiv:2405.13576, 2024.
[29] Gao Y, Xiong Y, Wang M, et al. Modular rag: Transforming rag systems into lego-like reconfigurable frameworks[J]. arXiv preprint arXiv:2407.21059, 2024.
[30] Xu R, Qi Z, Guo Z, et al. Knowledge conflicts for llms: A survey[J]. arXiv preprint arXiv:2403.08319, 2024.
[31] Kadavath S, Conerly T, Askell A, et al. Language models (mostly) know what they know[J]. arXiv preprint arXiv:2207.05221, 2022.
[32] Manakul P, Liusie A, Gales M J F. Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models[J]. arXiv preprint arXiv:2303.08896, 2023.
[33] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
[34] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
[35] Li T, Zheng R, Yang M, et al. Ditto: Motion-Space Diffusion for Controllable Realtime Talking Head Synthesis[J]. arXiv preprint arXiv:2411.19509, 2024.
[36] Li J, Xu Y, Lv T, et al. Dit: Self-supervised pre-training for document image transformer[C]//Proceedings of the 30th ACM international conference on multimedia. 2022: 3530-3539.
[37] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.
[38] Doersch C. Tutorial on variational autoencoders[J]. arXiv preprint arXiv:1606.05908, 2016.
[39] Hsu W N, Bolte B, Tsai Y H H, et al. Hubert: Self-supervised speech representation learning by masked prediction of hidden units[J]. IEEE/ACM transactions on audio, speech, and language processing, 2021, 29: 3451-3460.
[40] Liu A, Liu J, Pan Z, et al. Minicache: Kv cache compression in depth dimension for large language models[J]. Advances in Neural Information Processing Systems, 2024, 37: 139997-140031.